webir

clase 9

FACULTAD DE INGENIERIA
UNIVERSIDAD DE LA REPÚBLICA URUGUAY
INCO
Instituto de Computación
Facultad de Ingeniería
Universidad de la República

Temas

- IA generativa
- Riesgos
- Sistemas de Recuperación de Información y LLMs

Aprendizaje automático supervisado

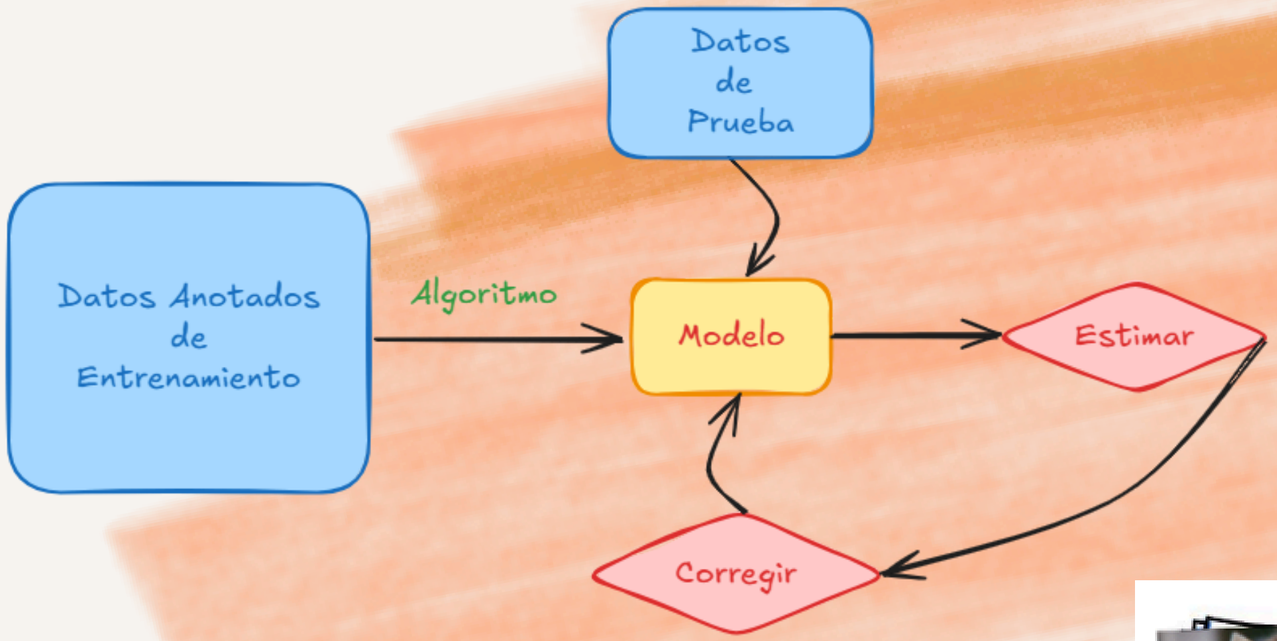

Entrada:
foto de gato
o
foto de otra cosa

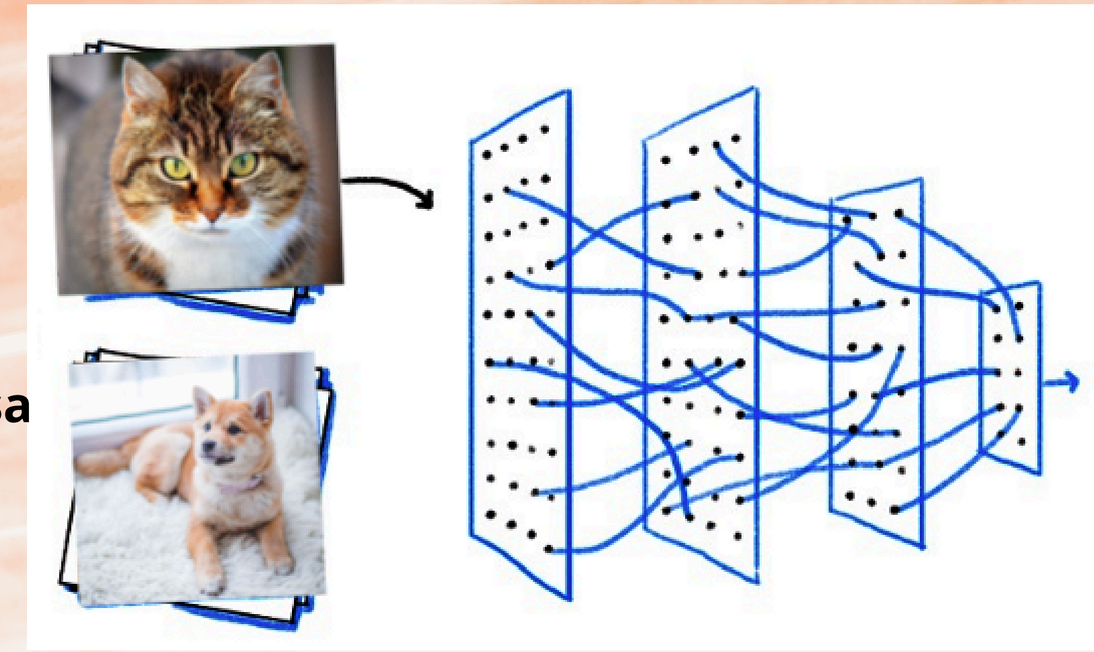

Salida:
es gato

Redes neuronales artificiales

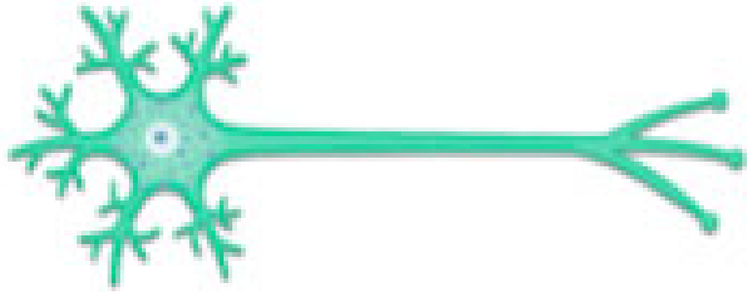

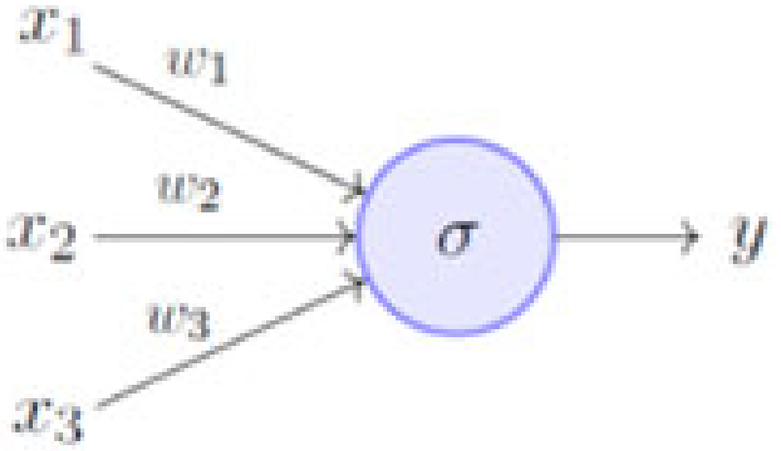

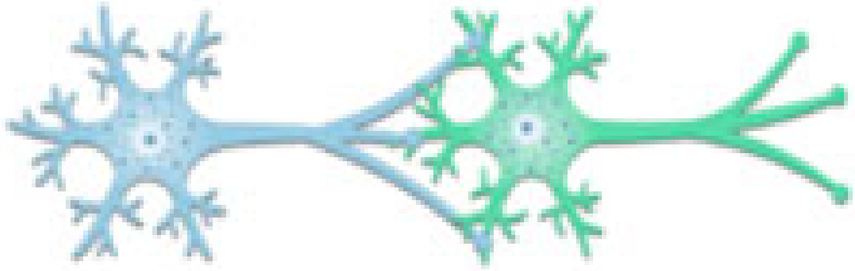

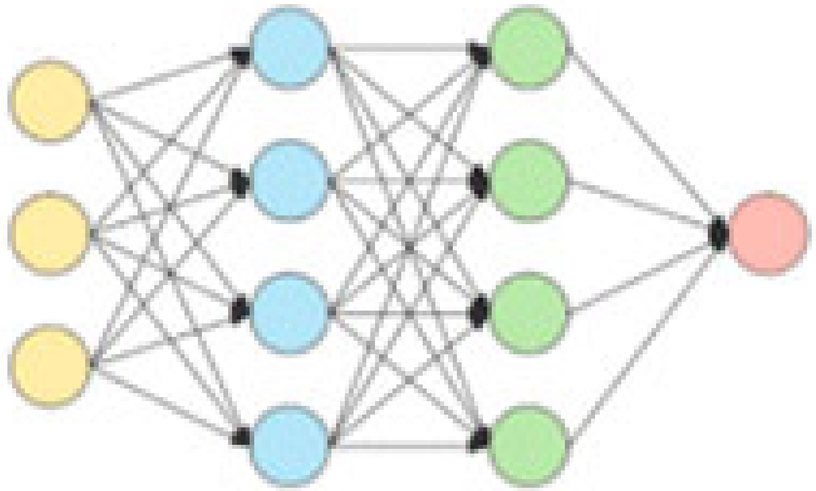

Grandes modelos de lenguajes - LLMs

"Attention is All you Need", **2017** por Vaswani, Shazeer, Parmar, Uszkoreit, Jones, Gomez, Kaiser, Polosukhin, de **google**.

- Arquitectura transformers para aprendizaje autosupervisado.
- Se entrena con gran cantidad de datos sin etiquetar ocultando secciones del texto, palabras, frases, etc., el modelo debe completar las palabras ocultas.
- Da como resultado un gran modelo de lenguaje.
- Permiten predecir la probabilidad de secuencias con suficiente confianza para crear o generar algo nuevo.

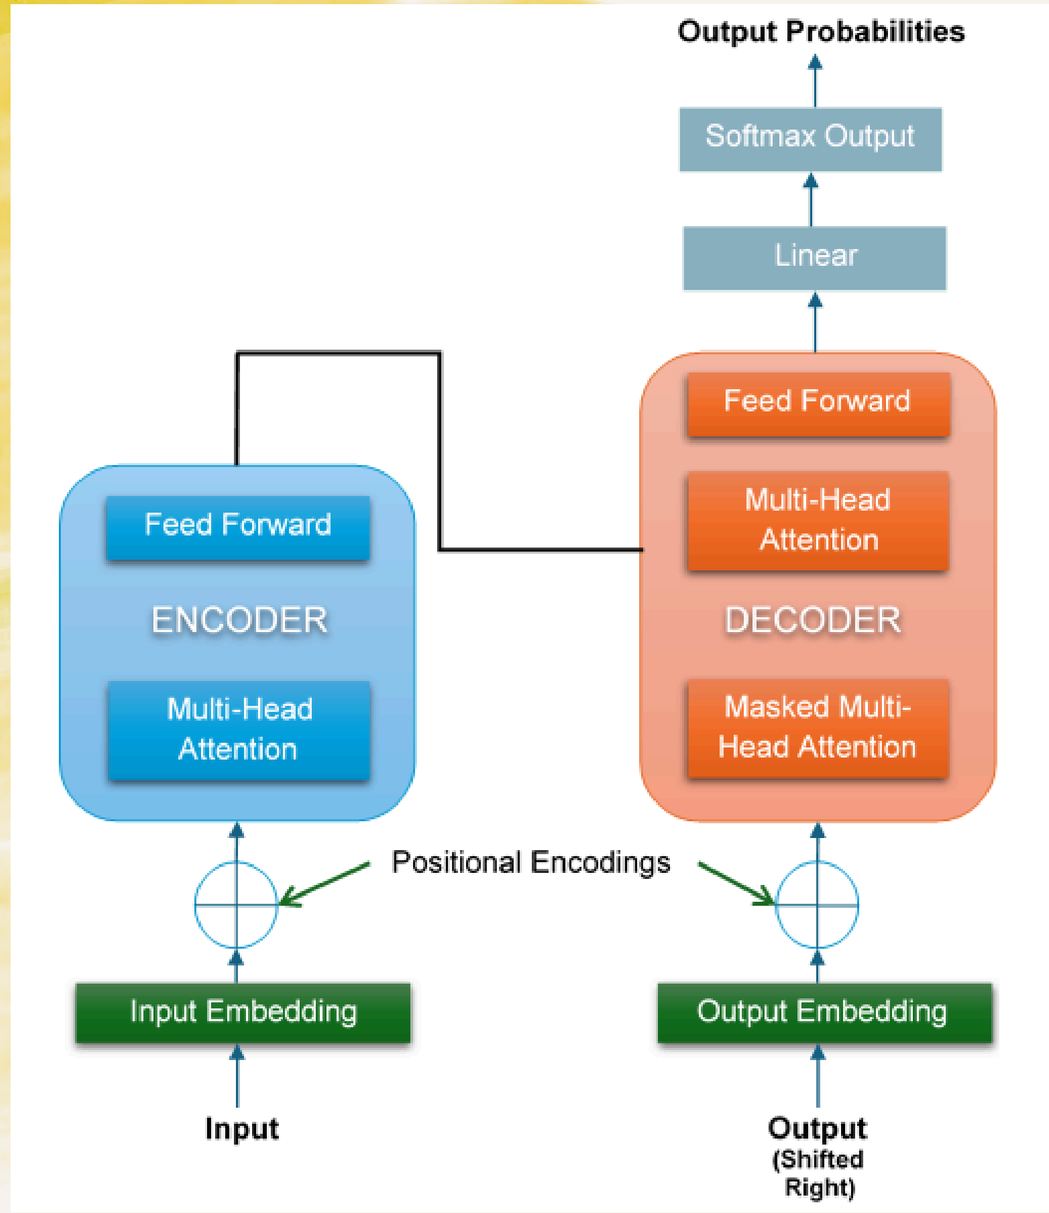

Grandes modelos de lenguajes - LLMs

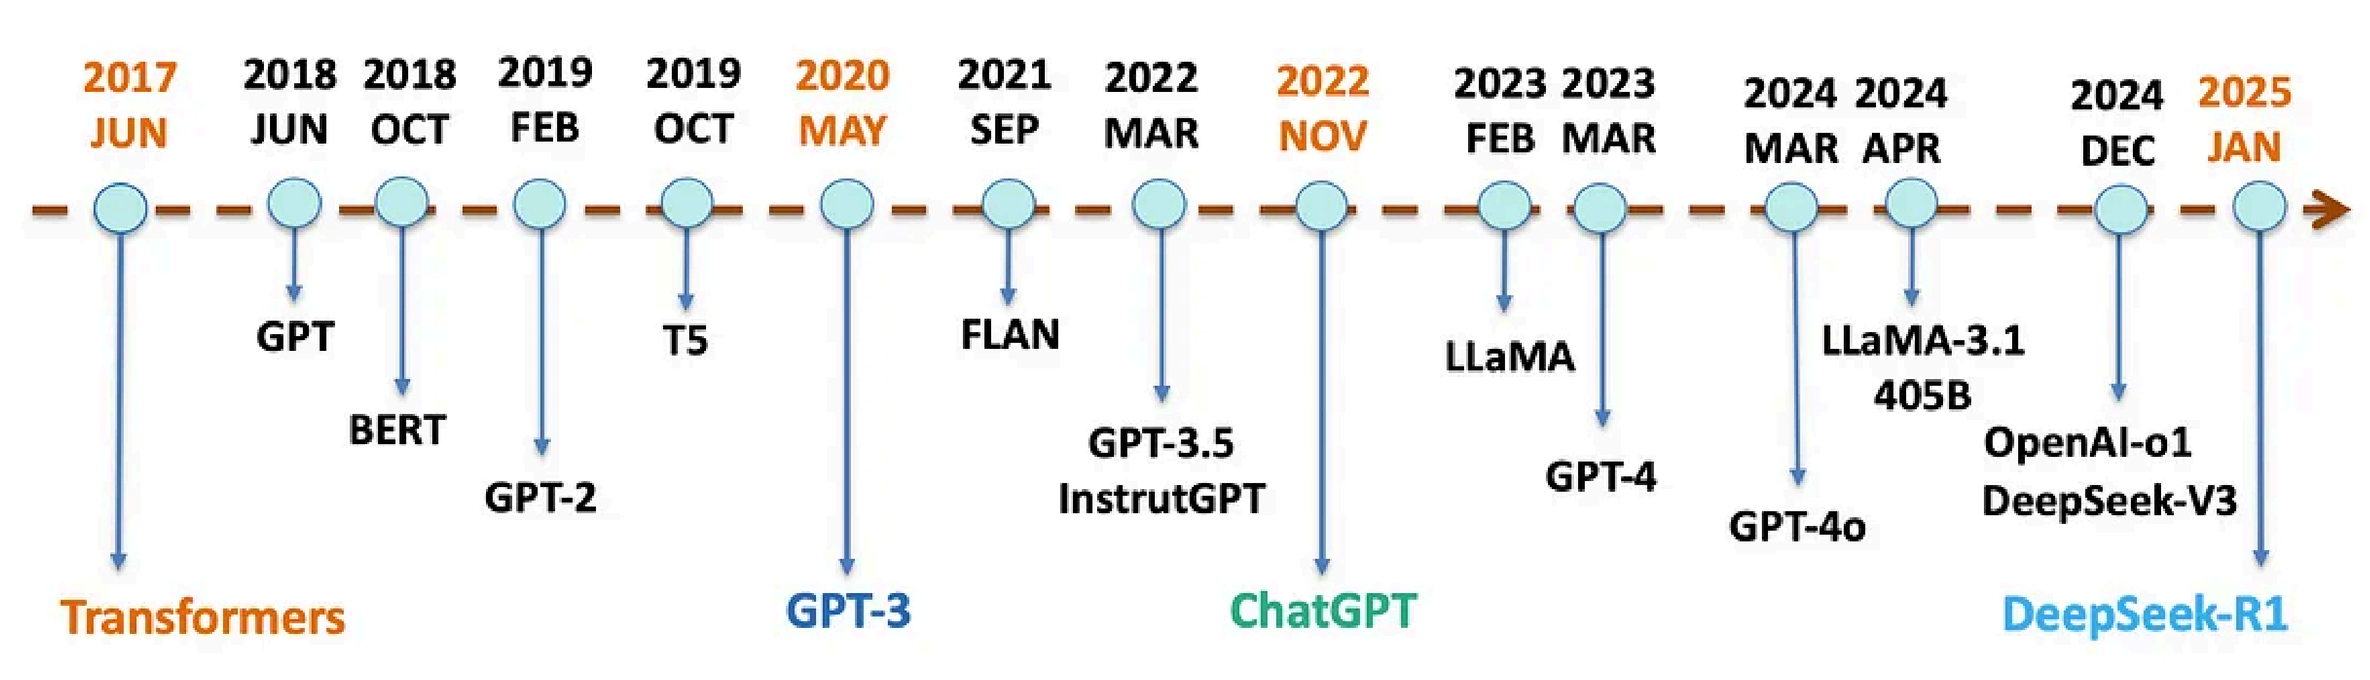

- Los LLM pueden entrenarse con grandes volúmenes de datos de internet y adquirir un conjunto de capacidades de lenguaje natural similares a las humanas.
- Permiten predecir la probabilidad de secuencias con suficiente confianza para crear o generar algo nuevo.

LLMs - Embeddings

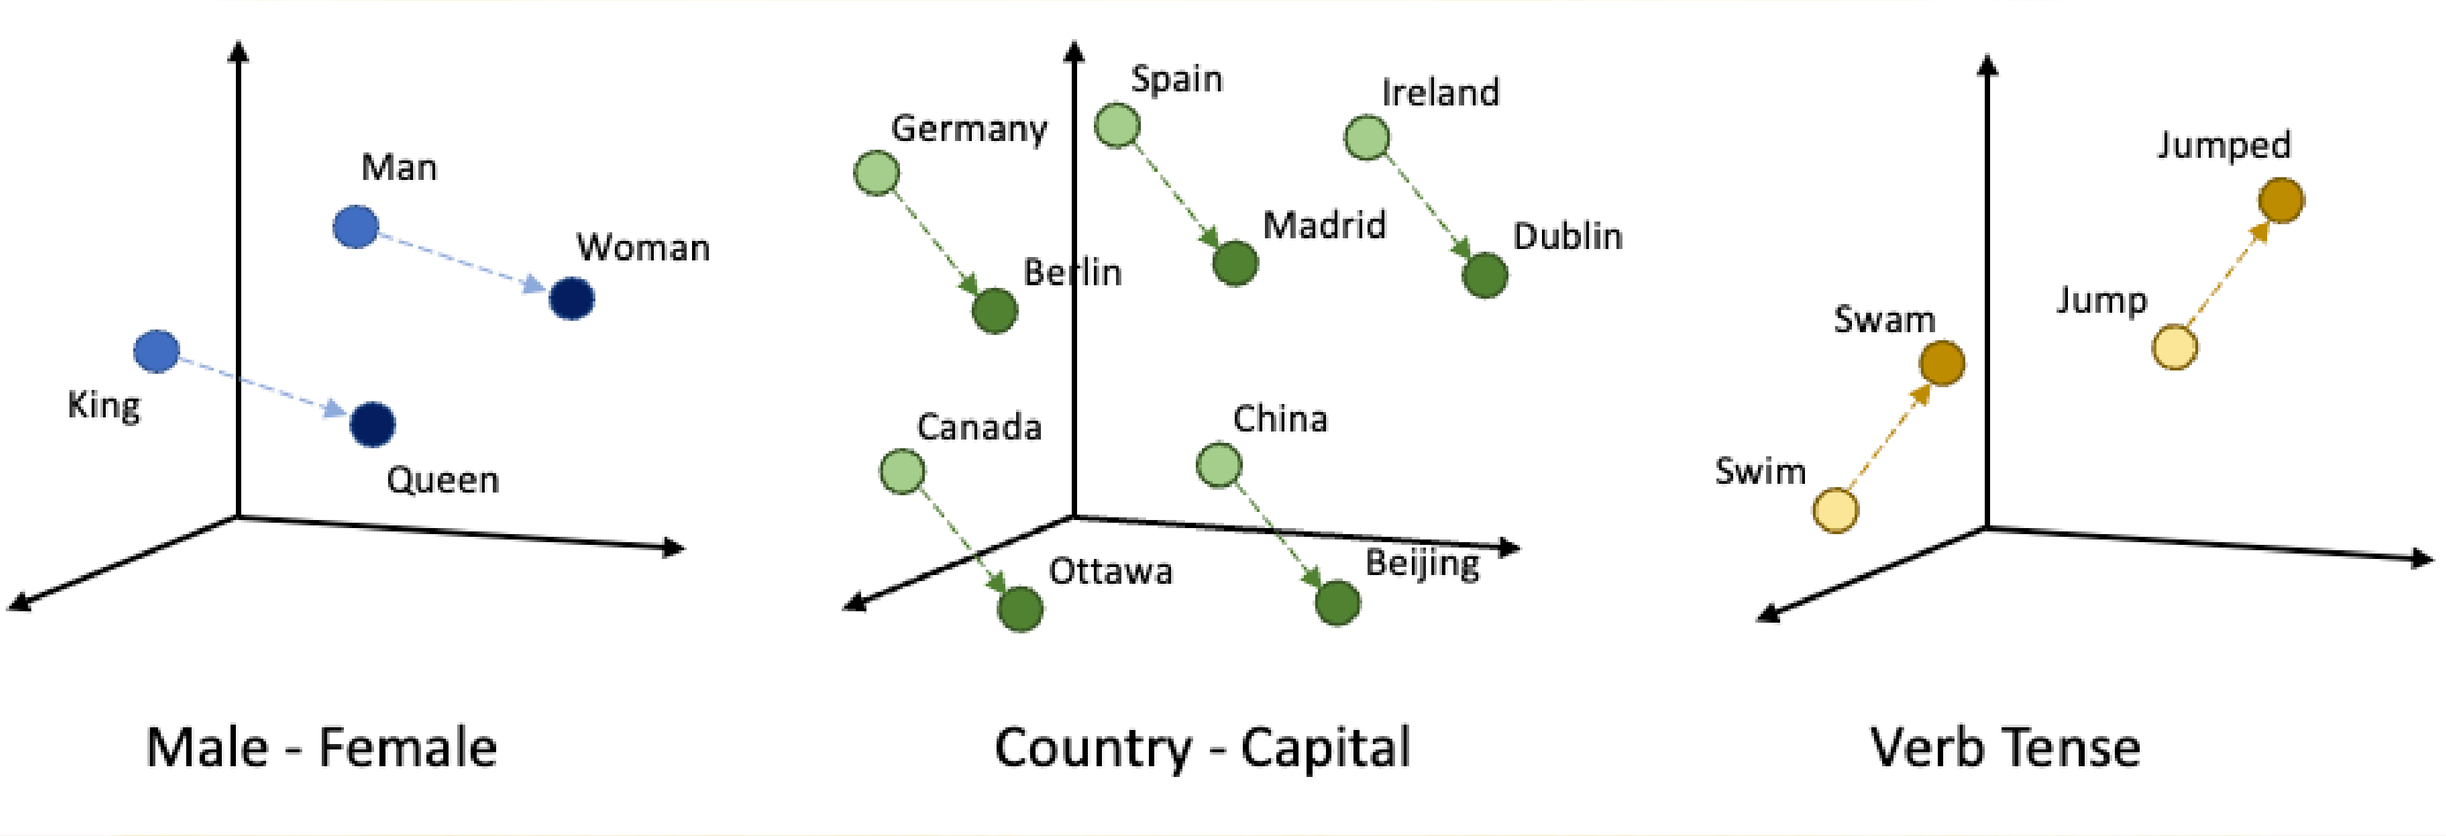

Importancia de los datos

- Las teorías y técnicas de IA se han desarrollado en paralelo a los avances en hardware.
- Drásticas reducciones de los costos de computación y almacenamiento.
- El tercer elemento importante son los datos.
- No hay IA generativa sin datos.

IA generativa

- Se aplica a lenguajes. ¿Qué es un lenguaje?
- Las señales en un equipo industrial pueden ser un lenguaje, los clics de un usuario navegando por un sitio web, el código de un software, secuencias de ADN, representaciones diagramáticas de químicos…
- Los modelos pueden especializarse para hacer todo tipo de tareas en cualquiera de esos lenguajes.

IA generativa - aplicaciones

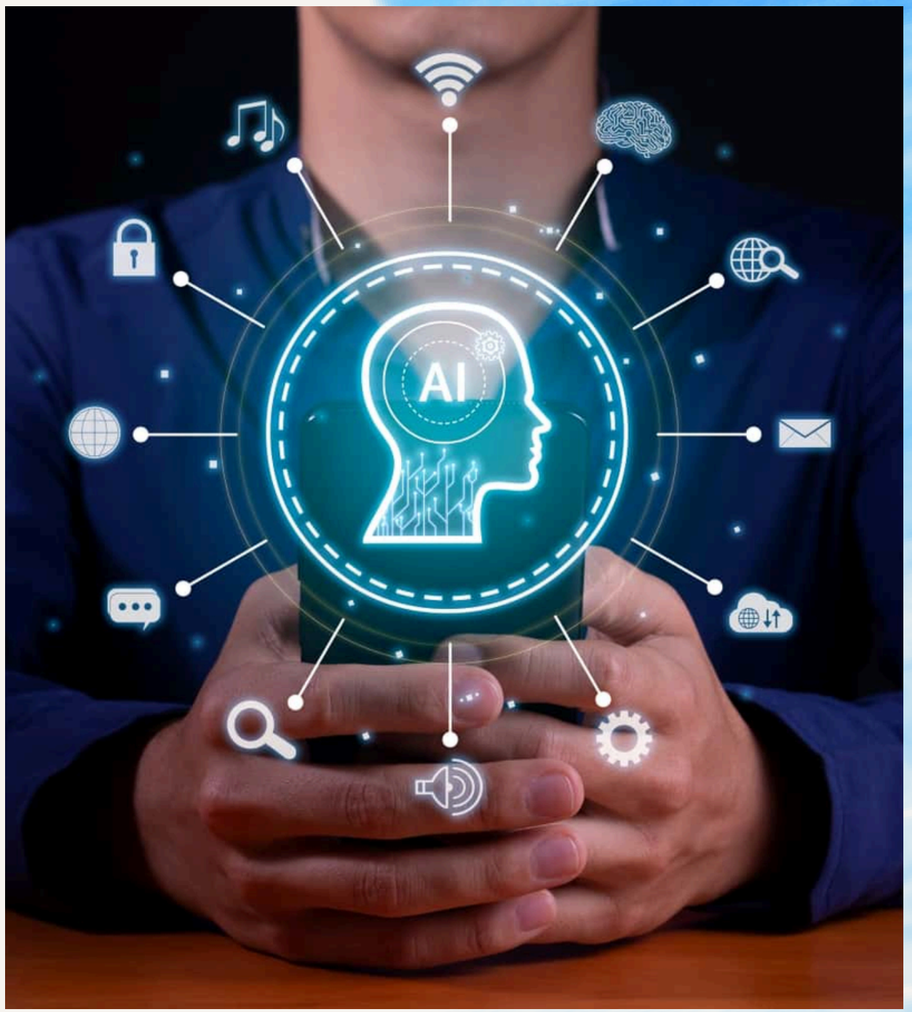

Ciberseguridad, efectos de mutaciones en secuencias de ADN, atención al cliente, escritura de código, logística, industria 4.0, control de tráfico, detección de accidentes y mucho más.

No es buena ni mala

- No solo afecta al mundo digital, también al mundo físico.
- ¿Puede permitir descubrir nuevos materiales, para la medicina, la energía, el clima, y otros tantos desafíos?
- Depende del uso.

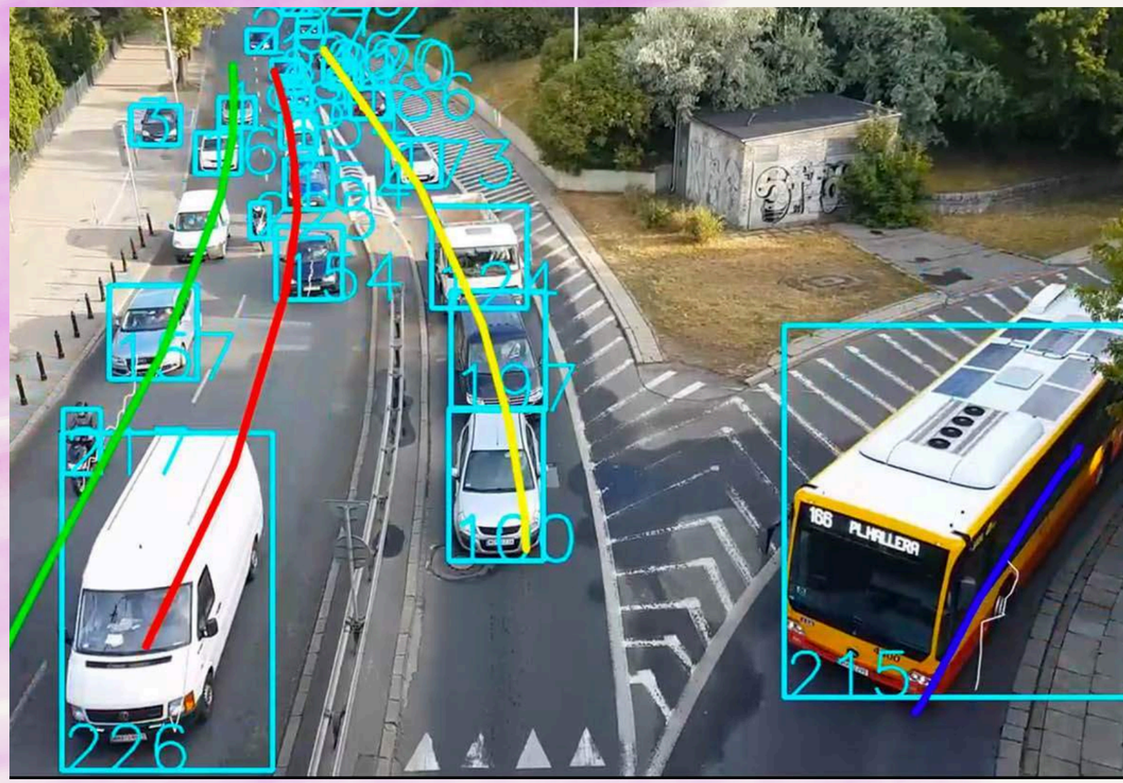

Servicios de IA

Servicio	Empresa	Fundadores/inversores	Especialidad	Tipo de LLM
GPT	OpenAI	Fundado entre otros por Elon Musk, Sam Altman CEO, inversiones de Microsoft	Conversaciones en lenguaje natural y respuestas sin perder el contexto.	LLMs propietarios.
Llama	Meta	Mark Zuckerberg, Yann LeCun científico jefe	LLM de código abierto, para investigación y desarrollo, disponible para descargar y personalizar.	LLMs de código abierto.
Gemini	Google	Liderado por Demis Hassabis (DeepMind, Google)	Análisis, síntesis de información y acceso a datos en tiempo real.	LLMs propietarios.
NotebookLM	Google		Sólo con documentos suministrados, más difícil que invente cosas o cometa errores. Basado en Gemini.	LLMs propietarios.
Perplexity	Perplexity	SoftBank, con sede en Tokio (Japón) , NVIDIA, ...	Se enfoca principalmente en la recuperación e investigación de información.	LLMs de código abierto.
DeepSeek	High-Flyer	Fondo de cobertura chino, uno de los fundadores es Liang Wenfeng CEO	Tareas técnicas como codificación, análisis de datos y cálculos matemáticos.	LLMs de código abierto.
CoPilot	Microsoft	Satya Nadella CEO y Kevin Scott	Desarrollo de código asistido.	LLMs de código abierto.
Claude	Anthropic	Dario y Daniela Amodei, hermanos exempleados de OpenAI - arreglar problemas de errores factuales y sesgos	Similar a ChatGPT.	LLMs propietarios.

ChatGPT - Generative Pretrained Transformer

- El uso implica permitir que recopile información del usuario.
- La empresa OpenAI almacena información variada de las cuentas de ChatGPT con la finalidad de “mejorar el servicio y personalizar las experiencias”.
- No tiene acceso directo a información personal y/o privada, pero registra aquella que el usuario proporcione durante las sesiones activas o incluso en forma posterior si así lo configura.

Ejemplo, en 2023 en la darkweb se vendían más de 100K cuentas de ChatGPT, sobre todo de Asia (https://www.group-ib.com/media-center/press-releases/stealers-chatgpt-credentials/).

Riesgos

- Datos
  - Almacenamiento de historiales de interacciones:
    - Información del usuario.
    - Contenidos.
- Resultados no veraces.
- Sesgos.

Riesgos - tipos de datos

- “Personales”, incluidas claves y credenciales:
  - No deberían darse nunca a ningún software.
- “Sensibles”, como nombres, edades, ubicaciones, ingresos, actividad:
  - Alternativas, p.e. **anonimización**.

Riesgos - sesgos

- Modelo COMPAS (Correctional Offender Management Profiling for Alternative Sanctions), utilizado sistemas judiciales EEUU para predecir la probabilidad de reincidencia.
- Debido a los datos utilizados, el algoritmo y el proceso de creación del modelo.
- Predecía el doble de falsos positivos de reincidencia en población afro (45%) que en blancos (23%).
- Detectado en 2016.

- Amazon gigante tecnológico.
- Modelo para la contratación de empleados presentaba sesgo contra las mujeres
- 2015.

Riesgos - mitigación

- Revisar términos y condiciones.
- Medir la información compartida, p.e. anonimizar información sensible.
- Recibir resultados de forma crítica.
- Cuidar sesgos.

Sistemas de IR y LLMs

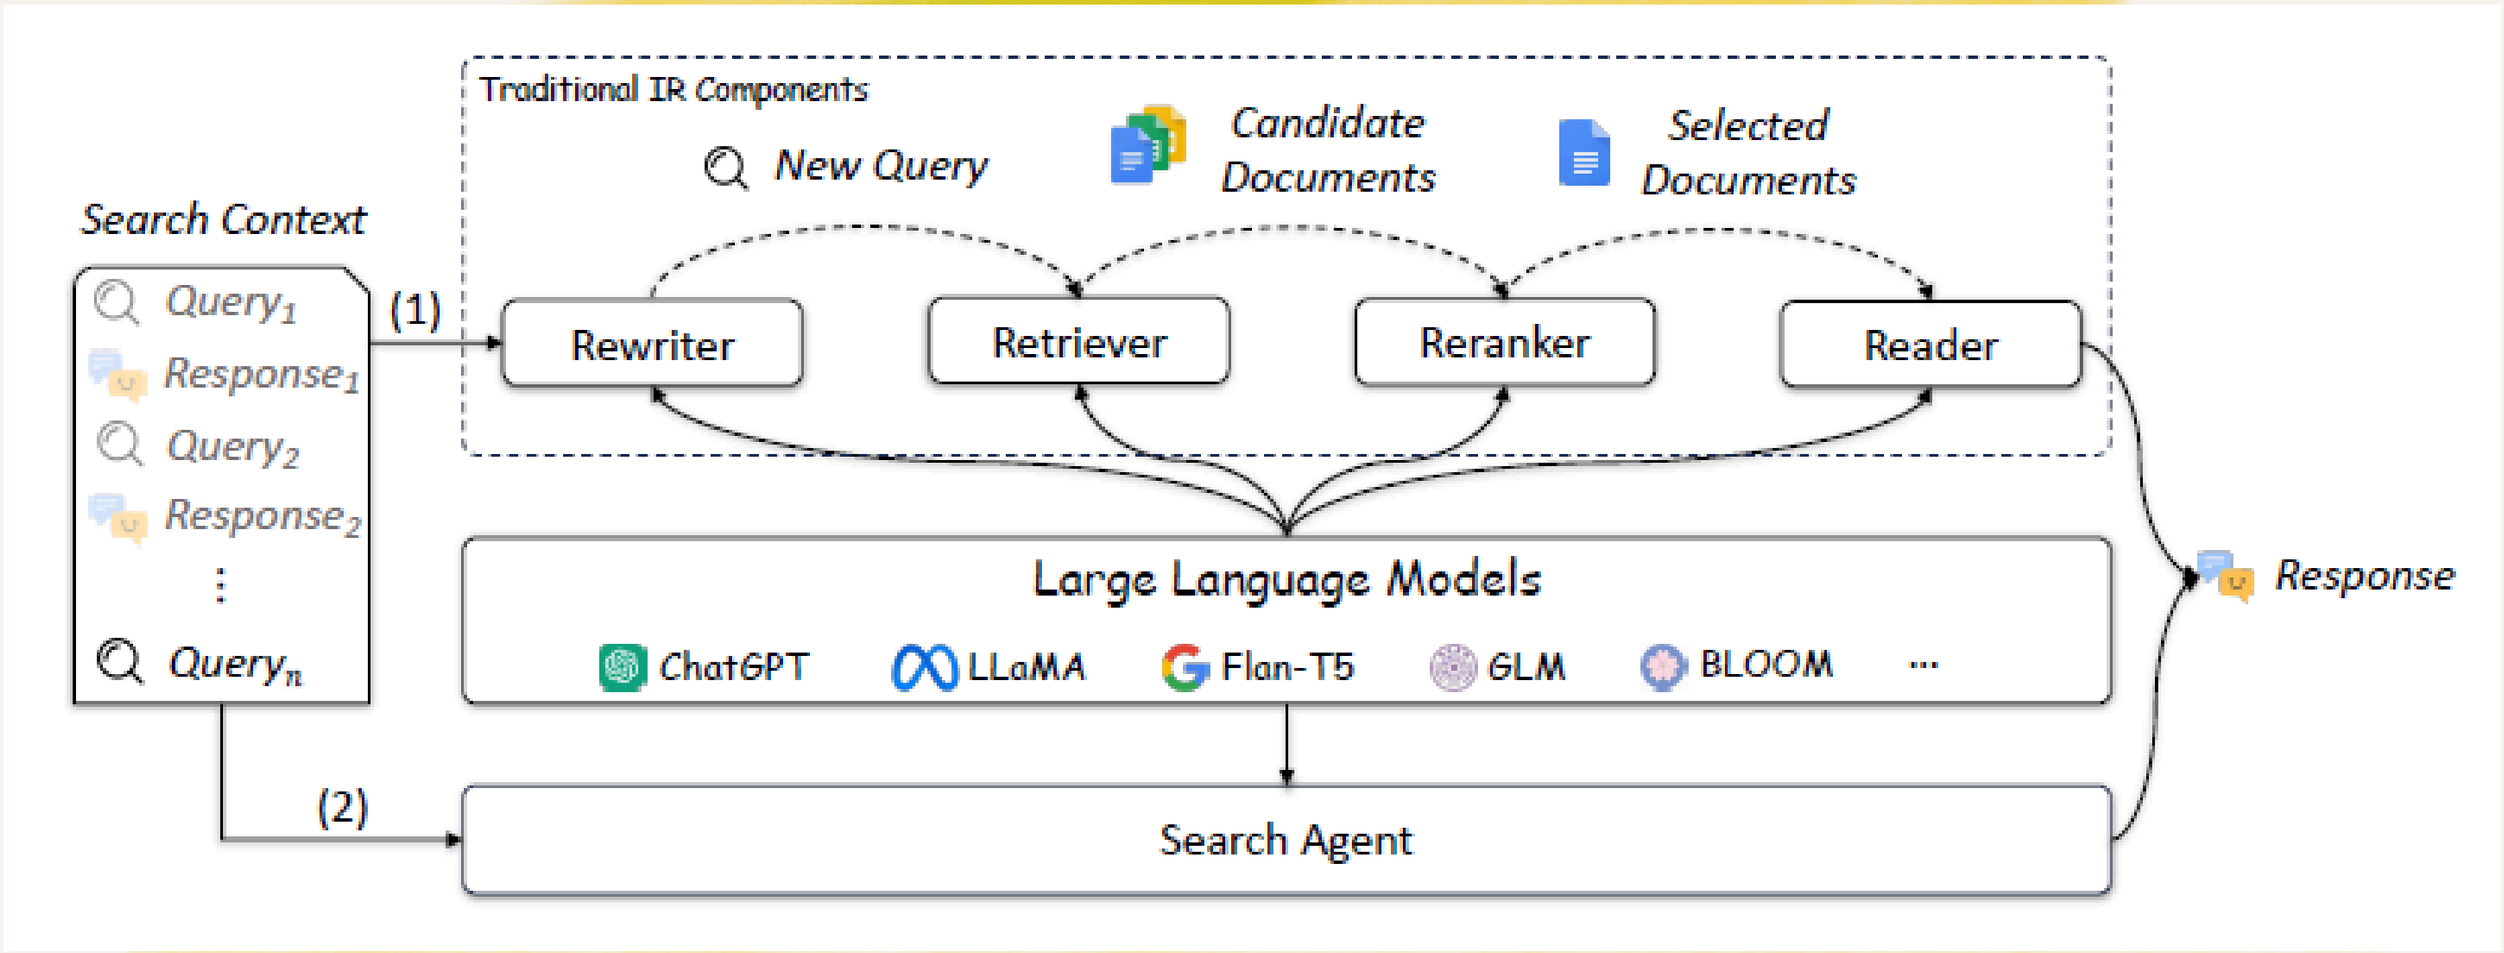

Módulos de un sistema de IR

Query Rewriter

- Mejorar la precisión y expresividad de las consultas.
- Refinar/modificar la consulta inicial para alinearse con la necesidad de información.
- Expansión de consultas, con feedback.
- Personalización, búsquedas conversacionales.

LLMs y sistemas de IR

Query Rewriter

- Recuperación ad hoc que aborda discordancia entre vocabulario de consultas y documentos candidatos.
  - LLMs aprovechan la semántica.
  - Entrenamientos en temas específicos.
- Búsquedas conversacionales que refina las consultas en función de la evolución de las conversaciones.
  - Capacidades de comprensión contextual permite interpretar mejor la intención de búsqueda de los usuario
- Métodos basados exclusivamente en el conocimiento intrínseco de los LLM vs métodos que incorporan corpus específicos del dominio.

LLMs y sistemas de IR

Query Rewriter

- Enfoques principales
  - **promting**: preguntas específicas para dirigir la producción del LLM, brindando flexibilidad e interpretabilidad.
  - **fine-tuning**: entrenamiento con datos o para tareas específicas para mejorar el rendimiento en el dominio.
  - **knowledge distillation**: modelos livianos específicos para la tarea de rescritura.

Módulos de un sistema de IR

Retriever

- La proyección de consultas y documentos en espacios vectoriales de alta dimensión y, posteriormente, calcular su relevancia con productos internos.
- Las representaciones vectoriales capturaran similitudes semánticas.

LLMs y sistemas de IR

Retriever

- Enfoques para mejorar el rendimiento de la recuperación a través de LLMs.
  - Refinamiento de datos de búsqueda, reformular consultas de entrada para capturar con más precisión las intenciones del usuario y/o resumiendo documentos extensos.
  - Ampliar datos de entrenamiento para modelos de recuperación de aprendizaje supervisado, por ejemplo basados en ANN.
- Eliminar índices invertidos
  - fine-tuning: con consultas y documentos
  - prompting: pueden dar resultados qué url contiene un documento respuesta porque fue entrenado con datos de internet.

Módulos de un sistema de IR

Reranker

- Reordenación dentro del conjunto de documentos recuperados.
- Énfasis en la calidad de la clasificación de los documentos.
- Estrategias especializadas adaptadas a satisfacer distintos requisitos de los usuarios, como personalización y resultados diversificados.
- Integración de objetivos para dominios específicos
- Mejoran la experiencia del usuario.

LLMs y sistemas de IR

Reranker

- LLMs como rerankers supervisados: fine-tuning.
- LLMs como rerankers no supervisados.
  - Obtener la relevancia de un documento para una consulta.
  - Dada una consulta y una lista de documentos, devolverlos ordenados por relevancia.
- LLMs para aumentar los datos de entrenamiento.
  - Construir nuevos conjuntos de entrenamiento sintéticos basados en las respuestas de un LLM a consultas de usuarios.

Módulos de un sistema de IR

Reader

- Presenta la lista de documentos candidatos, ordenados por relevancia, dando el comienzo del documento o una extracción relevante, y la url.

LLMs y sistemas de IR

Reader

- Evolucionado con el desarrollo de tecnologías LLM.
- Capacidad de comprensión de la intención del usuario en tiempo real y generar respuestas dinámicas basadas en el texto recuperado ha revolucionado la presentación de resultados.
- En contraposición con presentar una lista de documentos candidatos, organiza los textos de respuesta simulando la forma natural en que los humanos sintetizan la información.
- Para mejorar la credibilidad de las respuestas generadas, se integran referencias.

LLMs y sistemas de IR

Reader

- **Passive Reader**
  - Suministrar los documentos recuperados según las consultas como entradas para LLM para crear resúmenes.
- **Active Reader**
  - Se usan documentos recuperados según las consultas como entradas para un LLM.
  - El LLM puede solicitar/buscar más información, incluso al propio sistema de IR.
- **Compressor**
  - Resumir los documentos recuperados en fragmentos cortos.
  - Pueden ser usados como entrada a LLMs.

Desarrollo de IR

Search Agent

- Explorar la unificación de los módulos para desarrollar un nuevo modelo de búsqueda impulsado por LLM.
- Simulación de proceso automatizado de búsqueda comprensión de resultados para proporcionar información precisa y respuestas fácilmente comprensibles.
- Por ejemplo WebGPT [24] agente basado en LLM para todo el proceso de búsqueda. Nakano et. al. “Webgpt: Browser-assisted question-answering with human feedback,” CoRR, vol. abs/2112.09332, 2021.
- Static Agent
  - Imitar patrones de búsqueda humanos para navegar por la web y sintetizar la información paso a paso.
- Dynamic Agent
  - Entrenar LLM para usar motores de búsqueda automáticamente, mediante reinforcement learning en entorno simulado.

Desarrollo de IR y LLMs

RAG - Retrieval-Augmented Generation.

- Framework que combina la recuperación de información con LLMs para mejorar la calidad y la relevancia del contenido generado por IA.
- Recupera primero información relevante de fuentes externas para aumentar la información proporcionada al LLM.
- La información recuperada se incorpora a la entrada del LLM
  - Agregar directamente el texto recuperado.
  - Agregar un resumen.
- El LLM utiliza la entrada aumentada para generar una respuesta, incluyendo el conocimiento externo.
- Permite a los LLM acceder e integrar información más allá de sus propios datos de entrenamiento.
- Resultados más precisos, actualizados y contextualmente relevantes.

Sistema de IR y LLMs

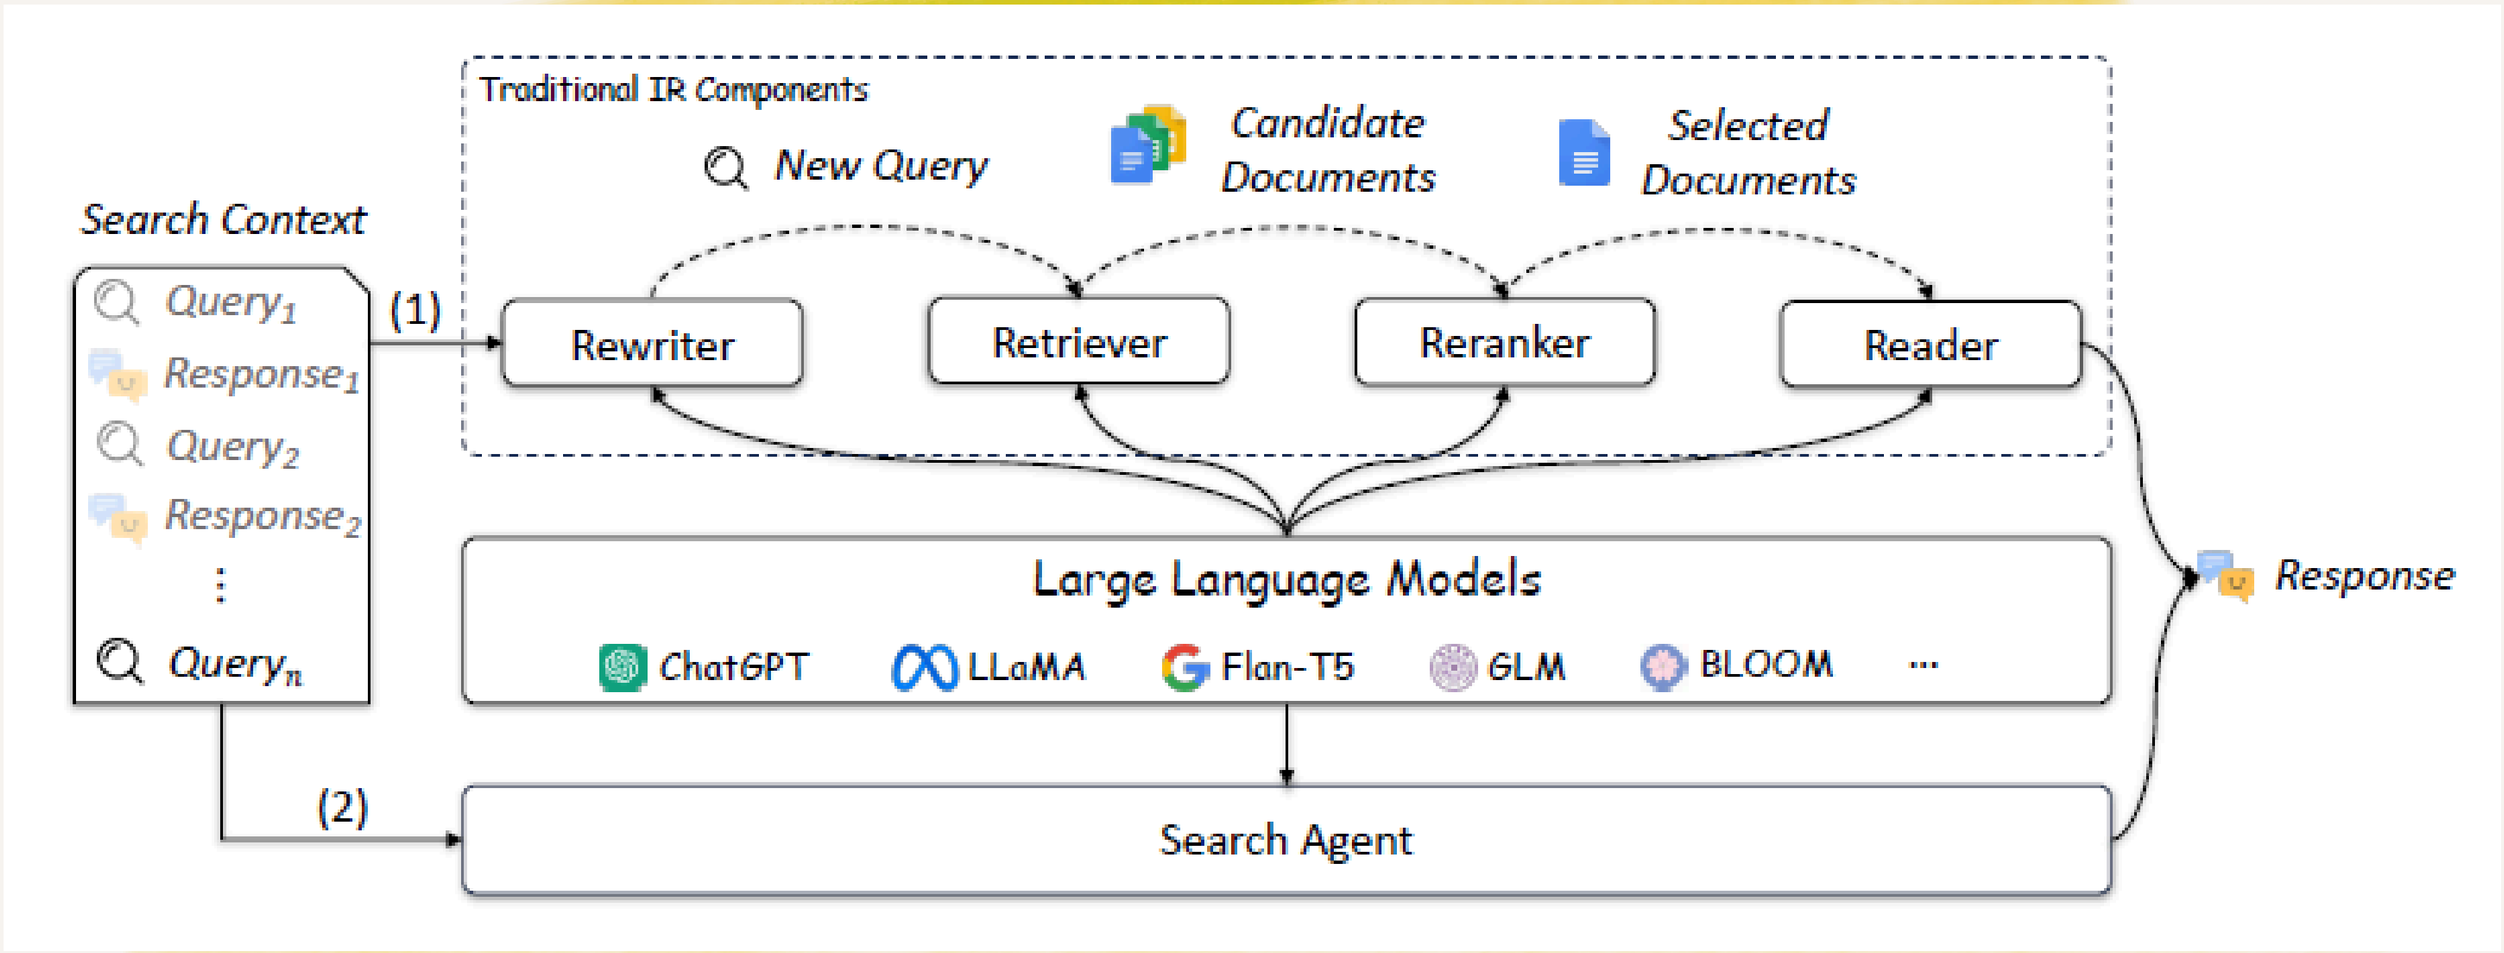

Futuro

- ¿Seguirá siendo útil el framework de IR o sustituidos por LLM?
- IR tradicional busca devolver una lista de documentos relevantes clasificados.
- Con LLMs se puede generar directamente respuestas consultas.
- Podría convertirse en un servicio auxiliar fundamental para diversos sistemas.